Rapport Du Projet

Introduction :

Avec l'avènement de l'**Internet Industriel des Objets (IIoT) 4.0**, les entreprises déploient des capteurs capables de collecter des **données environnementales en temps réel** pour surveiller et maintenir leurs installations. Le dataset que nous utilisons contient des mesures de **température** pour différentes pièces (room_id) à des moments précis (noted_date), ainsi que l'information sur l'emplacement du capteur (out/in).

Dans ce projet, nous utilisons des techniques de **deep learning pour prédire la température** en fonction de ces mesures. Ces prédictions permettent d'anticiper les variations thermiques, d'optimiser le confort ou la performance des systèmes, et de détecter d'éventuels problèmes avant qu'ils n'affectent l'infrastructure. Le modèle est capable de traiter les **grandes quantités de données à haute fréquence** et de révéler des **schémas cachés** que les méthodes traditionnelles ne détecteraient pas.

Importance des données :

Les mesures de température collectées dans ce dataset sont **cruciales pour de nombreux domaines** :

1. **Gestion des bâtiments –** Contrôle de la température pour le confort et l'efficacité énergétique.
2. **Maintenance prédictive –** Détection précoce des anomalies ou surchauffes dans différentes pièces ou équipements.
3. **Agriculture intérieure –** Suivi des conditions environnementales pour les serres ou cultures contrôlées.
4. **Centres de données et infrastructures critiques –** Surveillance pour éviter les surchauffes et optimiser le refroidissement.
5. **Analyse environnementale –** Comparaison de la température intérieure et extérieure (out/in) pour des insights sur l'isolation ou l'efficacité énergétique.

Ce dataset, bien que simple en apparence, est extrêmement **précieux pour des analyses avancées et des modèles prédictifs**, car il permet de traiter les **données temporelles et contextuelles** pour anticiper les variations de température et prendre des décisions informées.

1. Présentation générale

- **Nombre de lignes :** 97 606
- **Nombre de colonnes :** 5
- **Colonnes :**
  - id : identifiant unique de l'enregistrement

  - room_id/id : identifiant de la pièce
  - noted_date : date et heure de la mesure
  - temp : température mesurée (°C)
  - out/in : indique si la mesure est à l'intérieur (In) ou à l'extérieur (Out)
- **Types de données :**
  - id : objet (string)
  - room_id/id : objet (string)
  - noted_date : objet (string, à convertir en datetime pour l'analyse)
  - temp : int64
  - out/in : objet (string)
- **Valeurs manquantes :** aucune
- **Doublons :** 1 ligne dupliquée

2. Statistiques descriptives

- **Température (temp) :**
  - Minimum : 21°C
  - 25e percentile : 30°C
  - Médiane : 35°C
  - Moyenne : 35.05°C
  - 75e percentile : 40°C
  - Maximum : 51°C
  - Écart-type : 5.70°C
- **Répartition intérieur / extérieur (out/in) :**
  - In : 20 345 (approx.)
  - Out : 77 261 (approx.)
- Majorité des mesures sont extérieures.
- **Nombre de pièces (room_id/id) :** 1 unique (Room Admin)
- **Fréquence moyenne des mesures :** toutes les ~2 minutes

3. Visualisations:

  - Distribution des températures (temp)

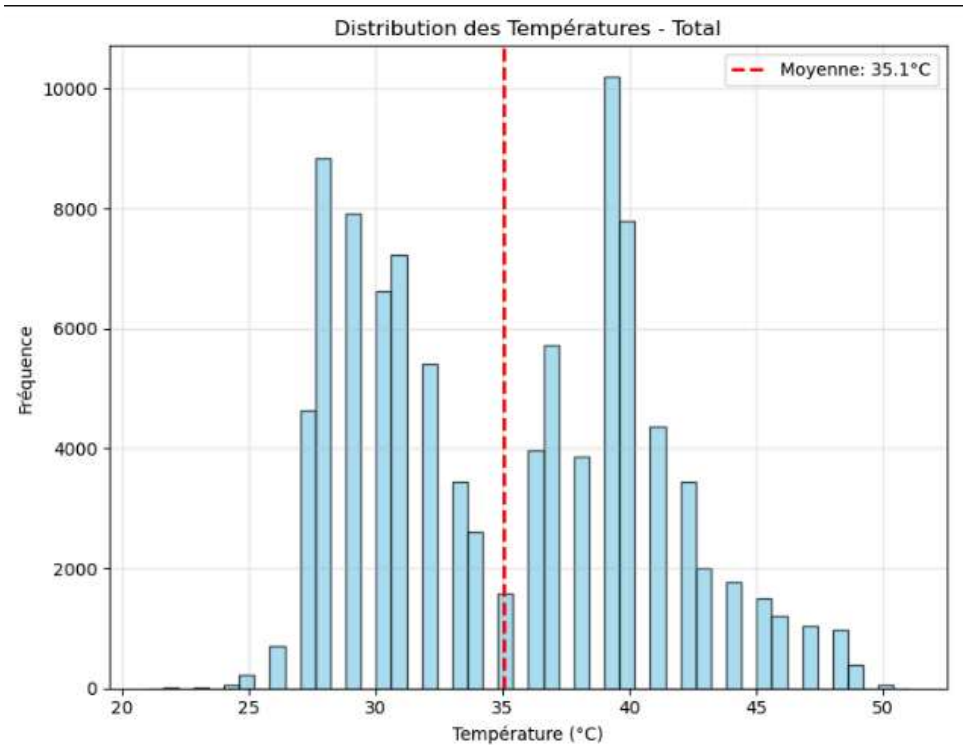

- Comparaison In vs Out

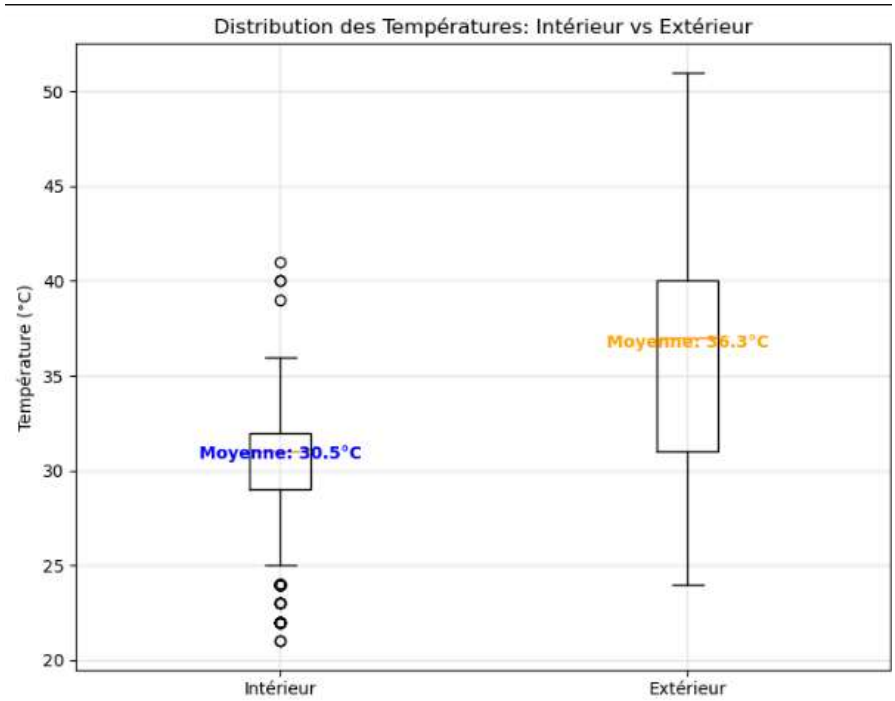

- Densité des Températures: Intérieur vs Extérieur

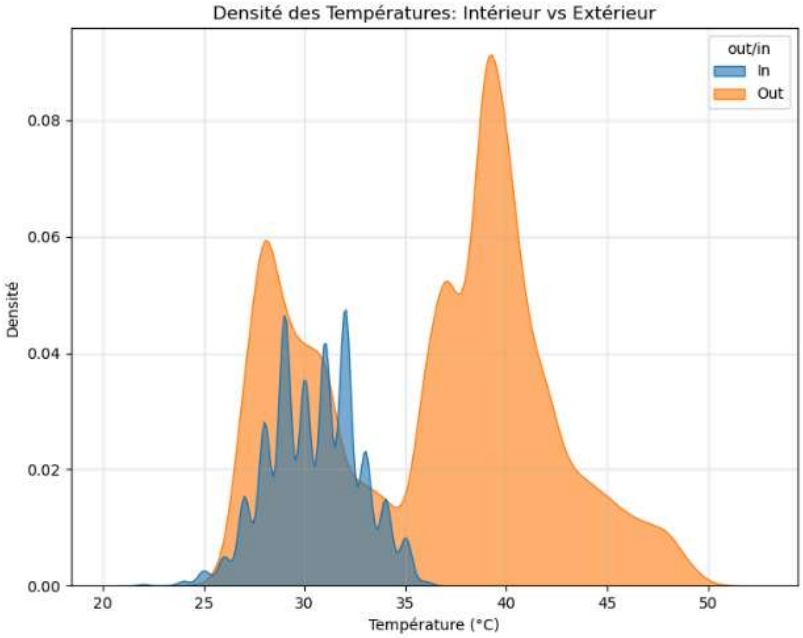

- Évolution des Températures au Fil du Temps\ Intérieur vs Extérieur

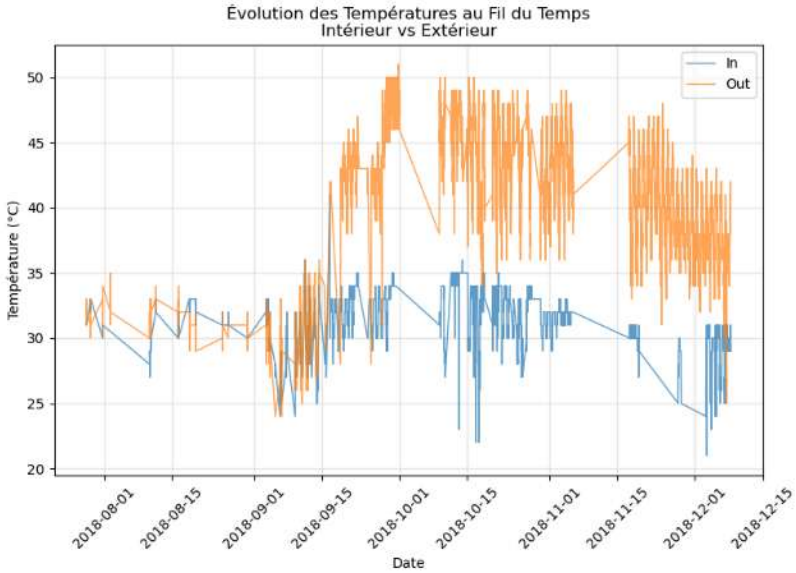

- Pattern Quotidien Moyen des Températures

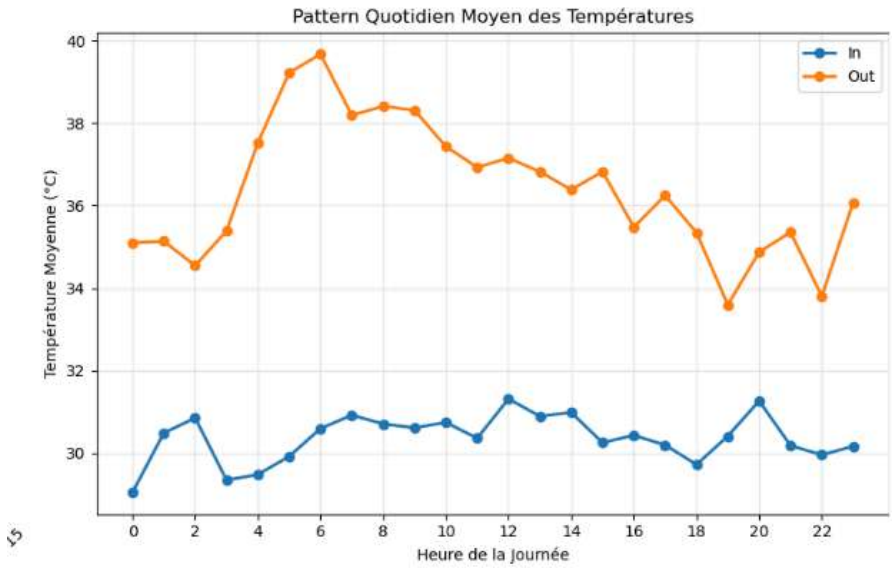

- Boxplots distribution de temperature par heure

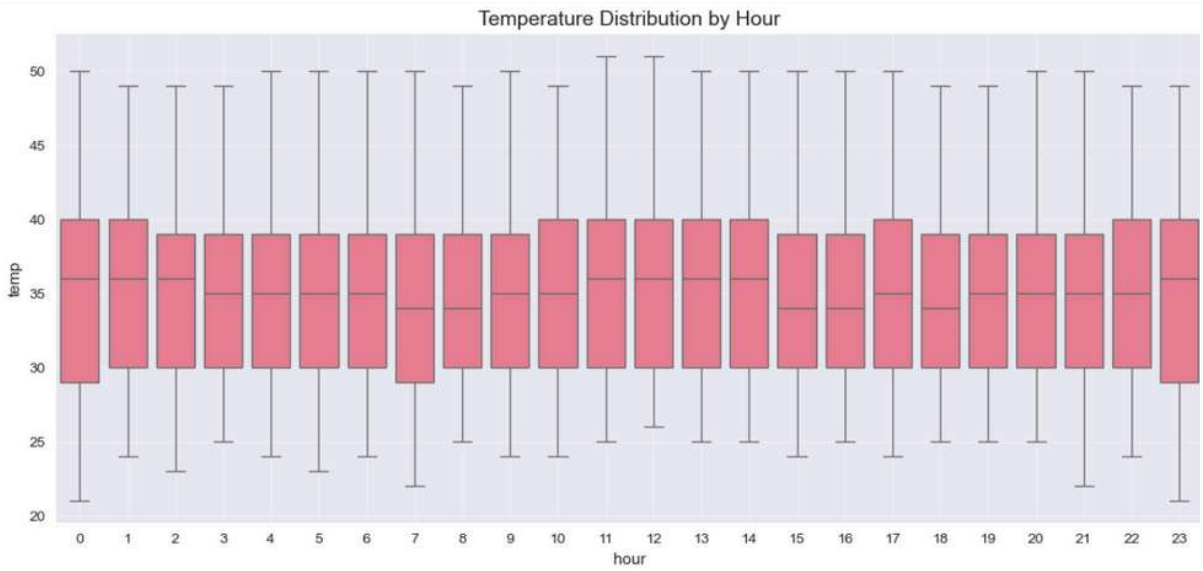

- Heatmap : Temperature par jour and heure

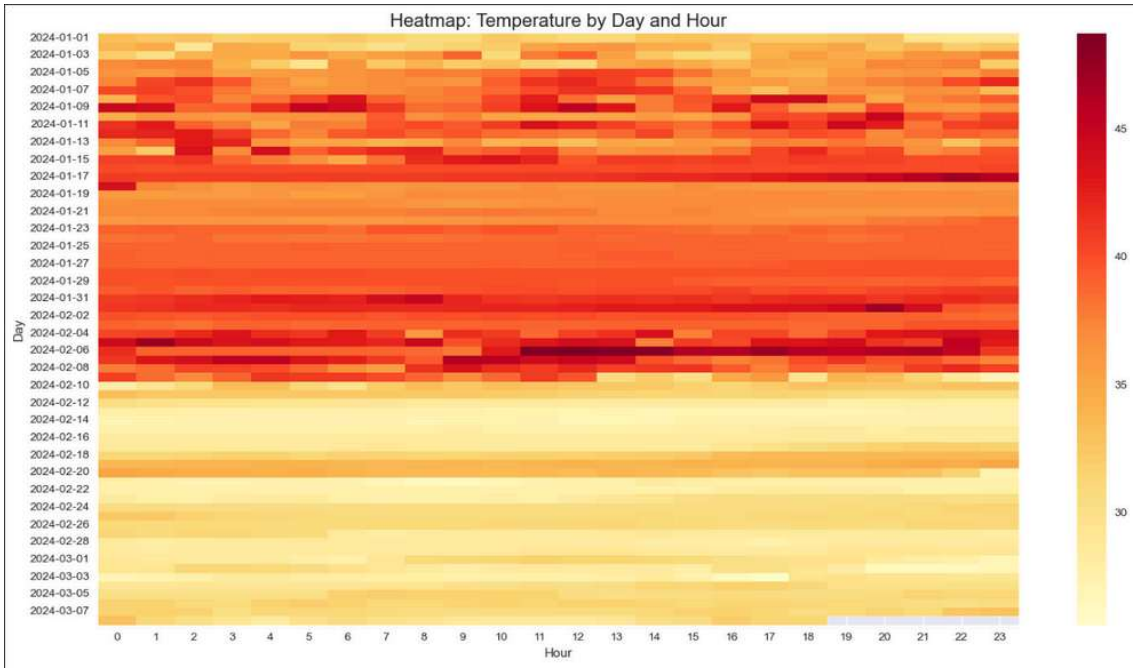

4.Prétraitement des données et préparation pour le modèle

Le dataset a été soigneusement nettoyé et préparé pour l'entraînement d'un modèle prédictif de température. Toutes les colonnes sont complètes, sans valeurs manquantes, et une seule ligne dupliquée a été supprimée pour garantir la qualité des données. La colonne noted_date a été convertie en type datetime afin d'extraire des features temporelles pertinentes, telles que l'heure, le jour et la minute. Les variables catégorielles, comme room_id et out/in, peuvent être encodées pour le modèle. La température, cible du modèle, est normalisée avec un MinMaxScaler pour que les valeurs soient comprises entre 0 et 1, ce qui permet aux modèles LSTM ou GRU de converger plus rapidement.

- Conversion des dates en features temporelles (jour, heure, minute).
- Suppression des lignes dupliquées (1 ligne).
- Encodage des variables catégorielles (room_id, out/in).
- Normalisation de la température avec MinMaxScaler (plage connue 21–51°C).
- Séparation chronologique du dataset en ensembles d'entraînement et de test (80/20).
- Utilisation d'un TimeSeriesSplit pour validation croisée respectant l'ordre temporel.

5. Approche Méthodologique / Modèle :

MACHINE LEARNING MODELS

Pour prédire la température dans les différentes pièces, plusieurs approches ont été testées, allant de modèles simples de référence (baselines) à des modèles de machine learning plus avancés. L'objectif est de comparer leurs performances afin d'identifier le modèle le plus précis et le plus fiable pour des prévisions temporelles. Les métriques utilisées pour l'évaluation incluent le RMSE, le MAE et le coefficient de détermination R^2.

1-Baseline Models

Les modèles de référence (baseline) permettent d'évaluer la performance minimale attendue pour la prédiction de température. Deux approches ont été utilisées : la persistance (la température reste la même que la dernière mesure) et la prévision par la médiane historique.

- **Persistence** :
  - RMSE : 3.357
  - MAE : 1.308
- **Median Forecasting** :
  - RMSE : 3.020
  - MAE : 1.082

Ces modèles fournissent une référence simple pour comparer les modèles plus sophistiqués.

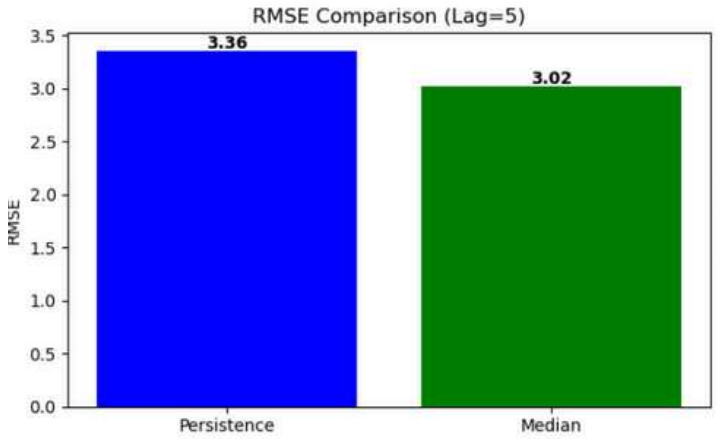

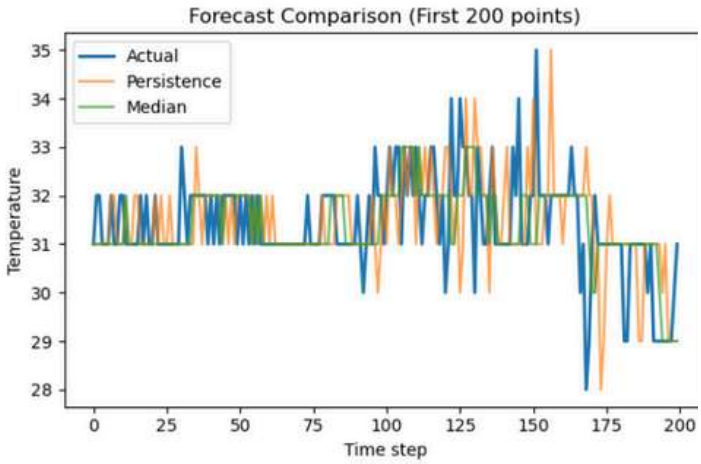

2-Linear Regression

Le modèle de régression linéaire a été testé sur les ensembles train et test. Il montre de bonnes performances sur l'ensemble d'entraînement mais échoue à généraliser sur le test set, dépassant la baseline.

- **Train Set** :
  - RMSE : 1.455
  - MAE : 0.714
  - R^2 : 0.934
- **Test Set** :
  - RMSE : 3.235
  - MAE : 2.063
  - R^2 : 0.637

Comparé à la baseline médiane, le modèle de régression linéaire est **90,6 % plus mauvais** sur le test set.

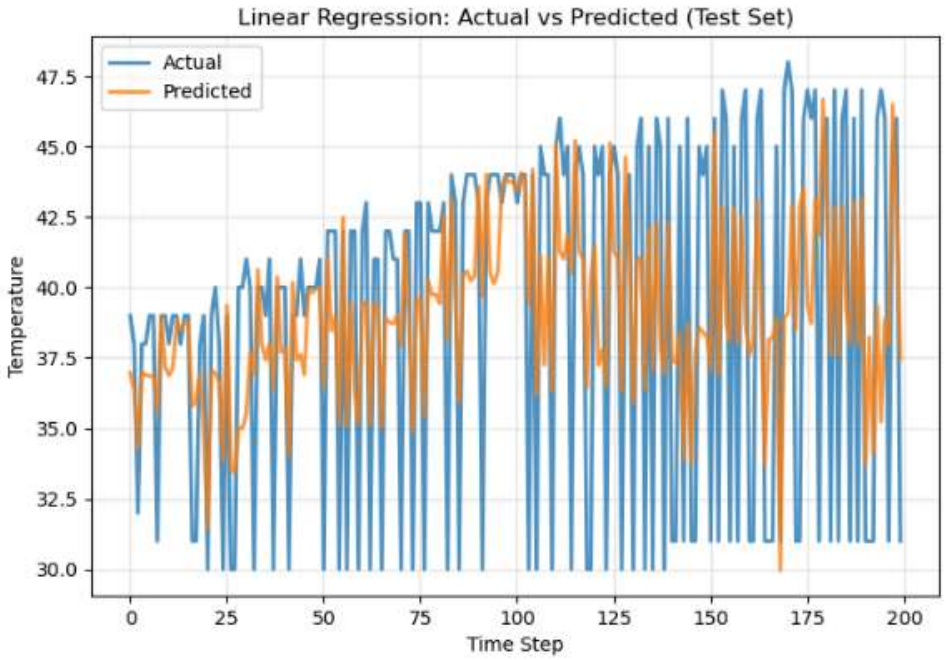

3- XGBoost

Le modèle XGBoost montre une performance exceptionnelle avec une très bonne capacité de généralisation, surpassant largement les baselines et la régression linéaire.

- **Train Set** :
  - RMSE : 0.094
  - MAE : 0.046
  - R^2 : 1.000
- **Test Set** :
  - RMSE : 0.545
  - MAE : 0.266
  - R^2 : 0.990

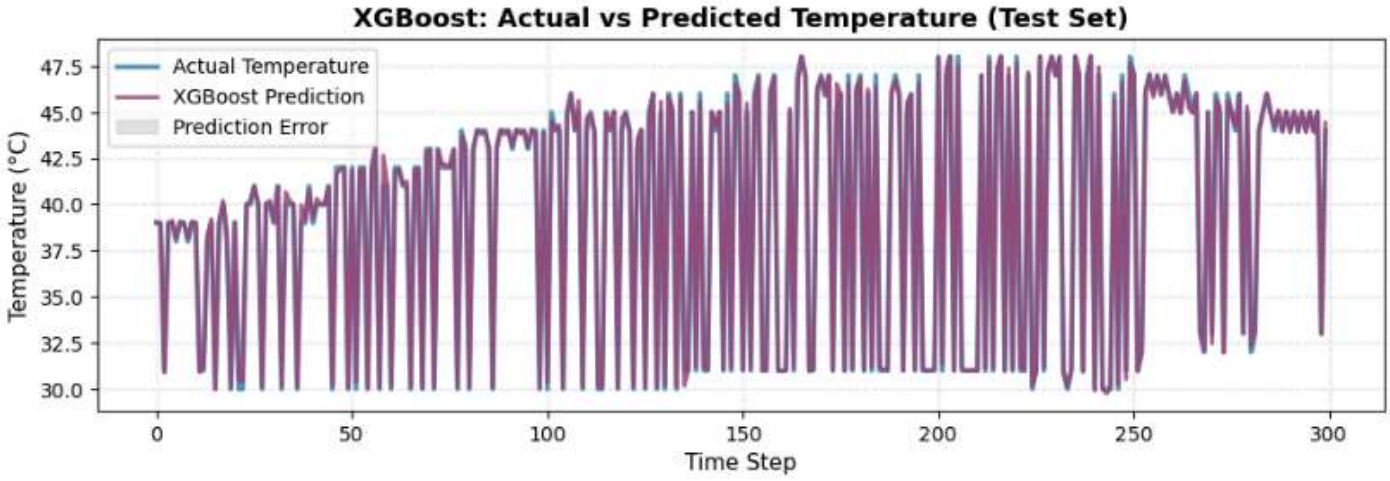

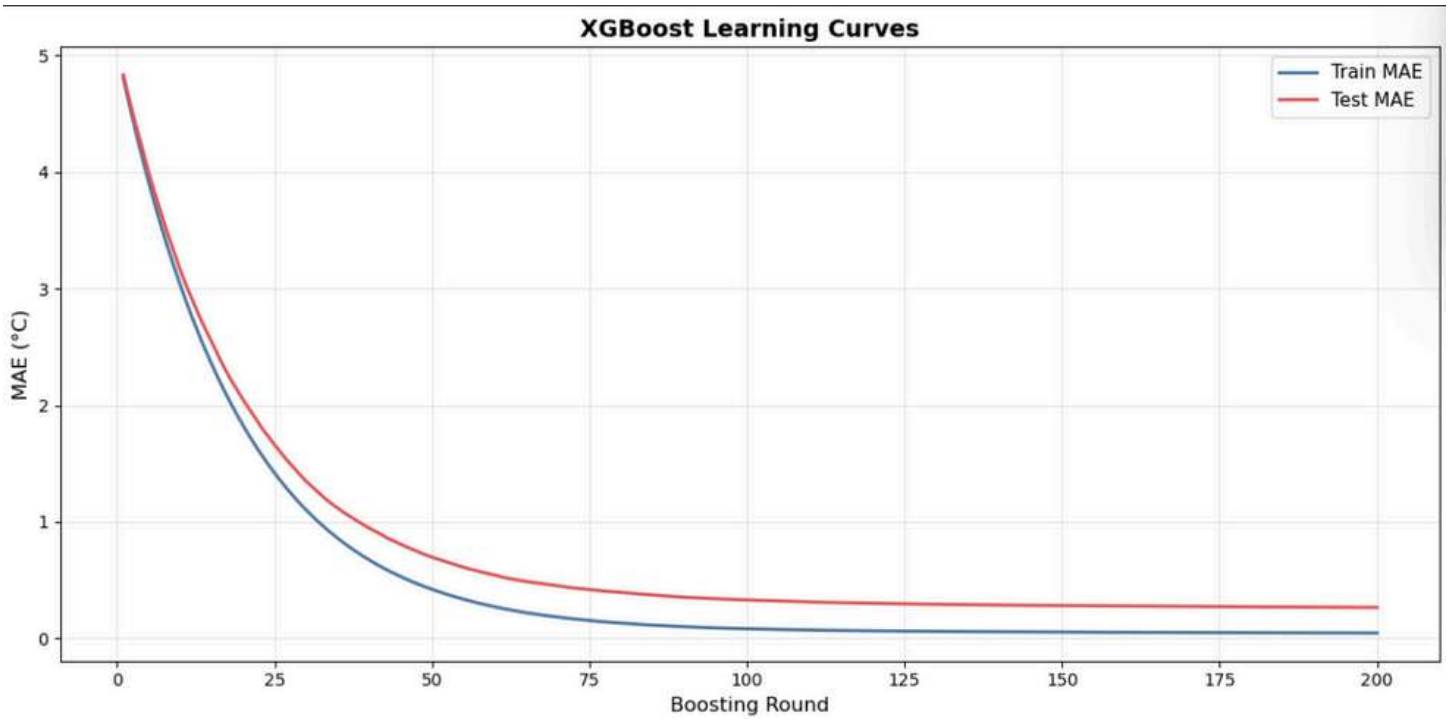

4- SARIMA

Le modèle SARIMA (Seasonal ARIMA) a également été testé pour capturer les tendances et la saisonnalité dans les données temporelles.

- **Test Set** :
  - RMSE : 3.557

Le SARIMA montre une performance similaire à la baseline persistence et moins efficace que XGBoost pour ce dataset.

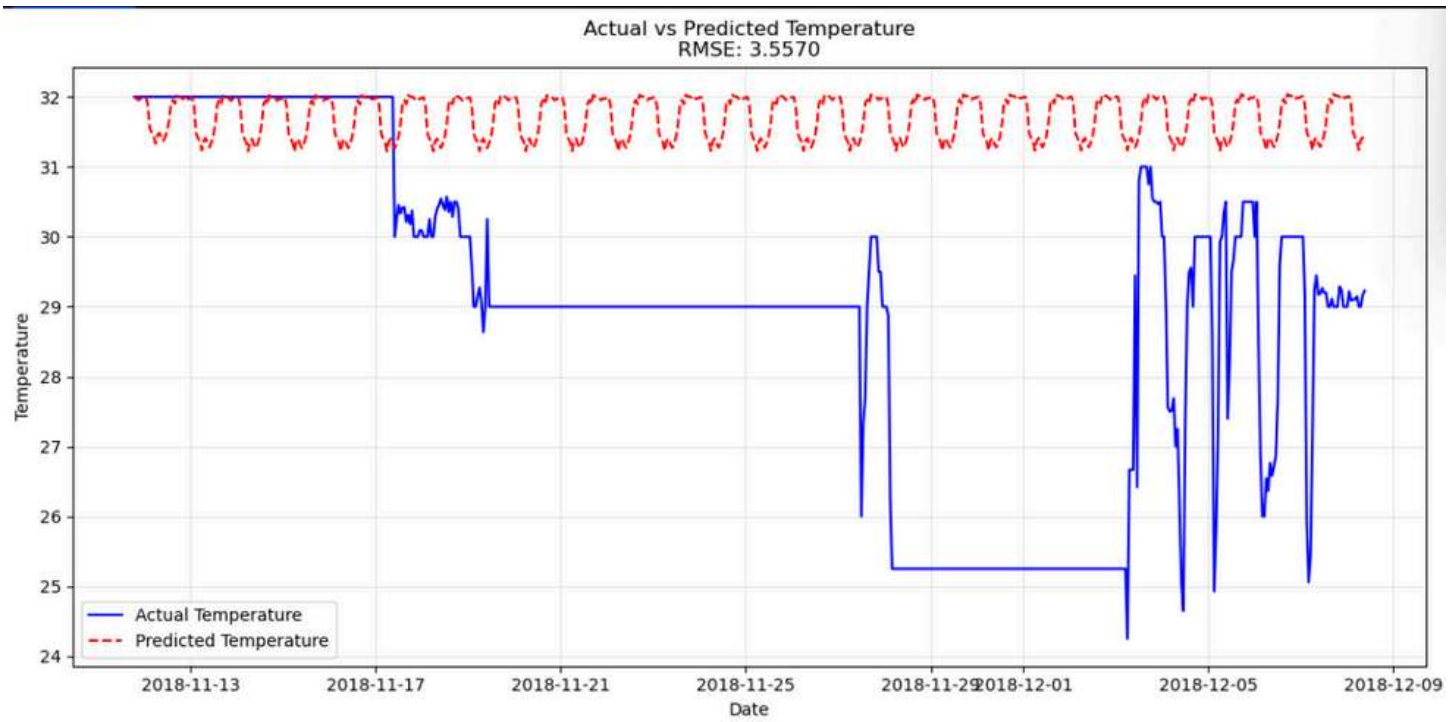

Comparé aux baselines et à la régression linéaire :

- Amélioration par rapport à la baseline médiane : 75,4 %
- Amélioration par rapport à la régression linéaire : 87,1 %

Parmi les modèles testés, **XGBoost** est clairement le plus performant pour la prédiction de température, avec un MAE très faible et une excellente capacité de généralisation sur le jeu de test. Les modèles simples comme la régression linéaire ne suffisent pas à capturer la complexité temporelle des données.

Deep Learning Models

Plusieurs modèles de deep learning ont été testés pour capturer la complexité temporelle et les patterns non linéaires dans les données de température. L'objectif est de comparer leurs performances finales sur le jeu de test.

LSTM (Long Short-Term Memory)

Le modèle LSTM est conçu pour exploiter la dépendance temporelle des séries de température.

- Final RMSE : 0.894
- Nombre de nœuds : 128

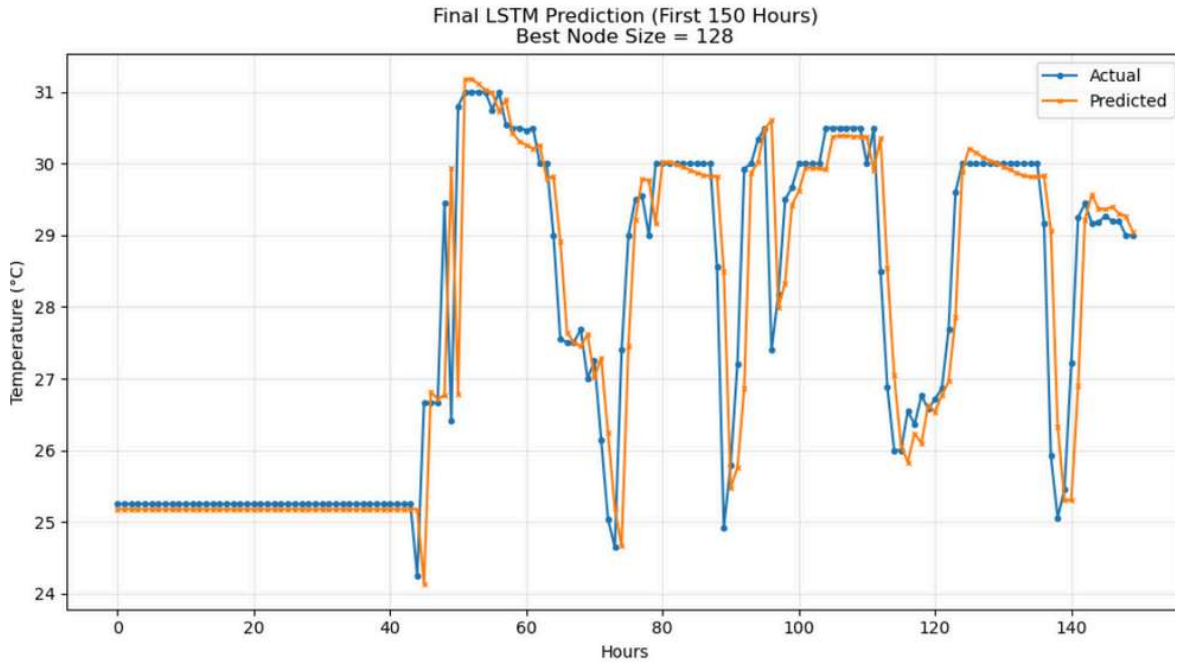

Multilayer Perceptron (MLP)

Le MLP, un réseau de neurones dense, a été entraîné pour prédire la température à partir des features extraites.

- Final RMSE : 0.960 ± 0.048

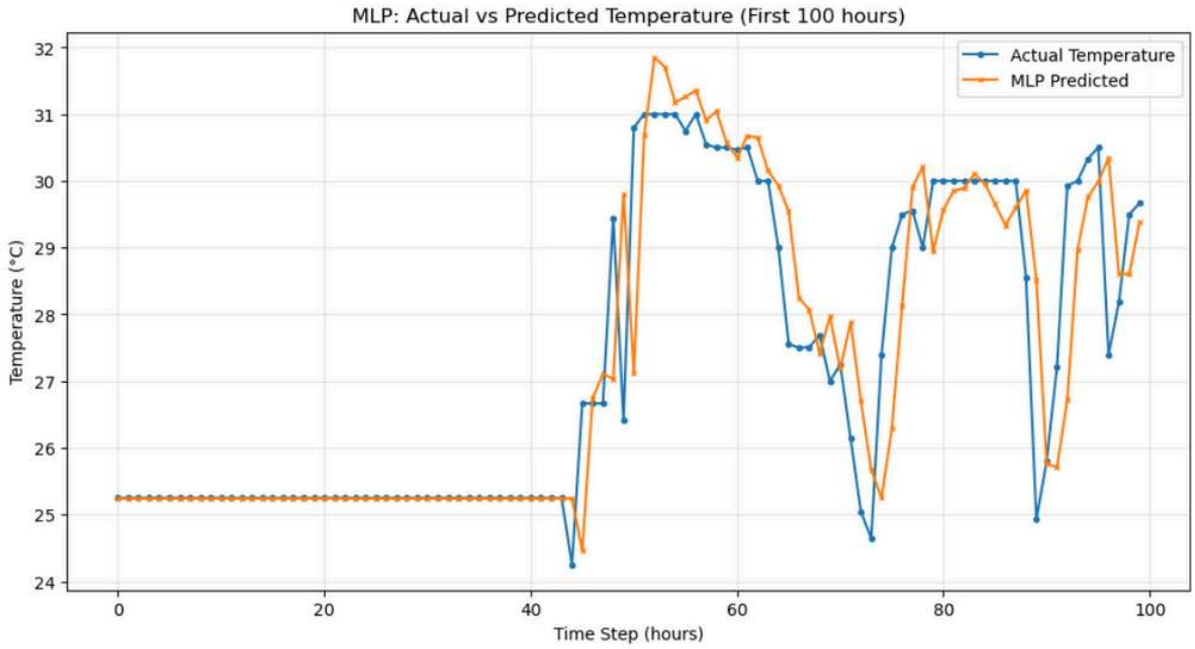

1D Convolutional Neural Network (1D CNN)

Le 1D CNN a été utilisé pour détecter les motifs locaux dans la série temporelle.

- Final RMSE : 0.976± 0.063

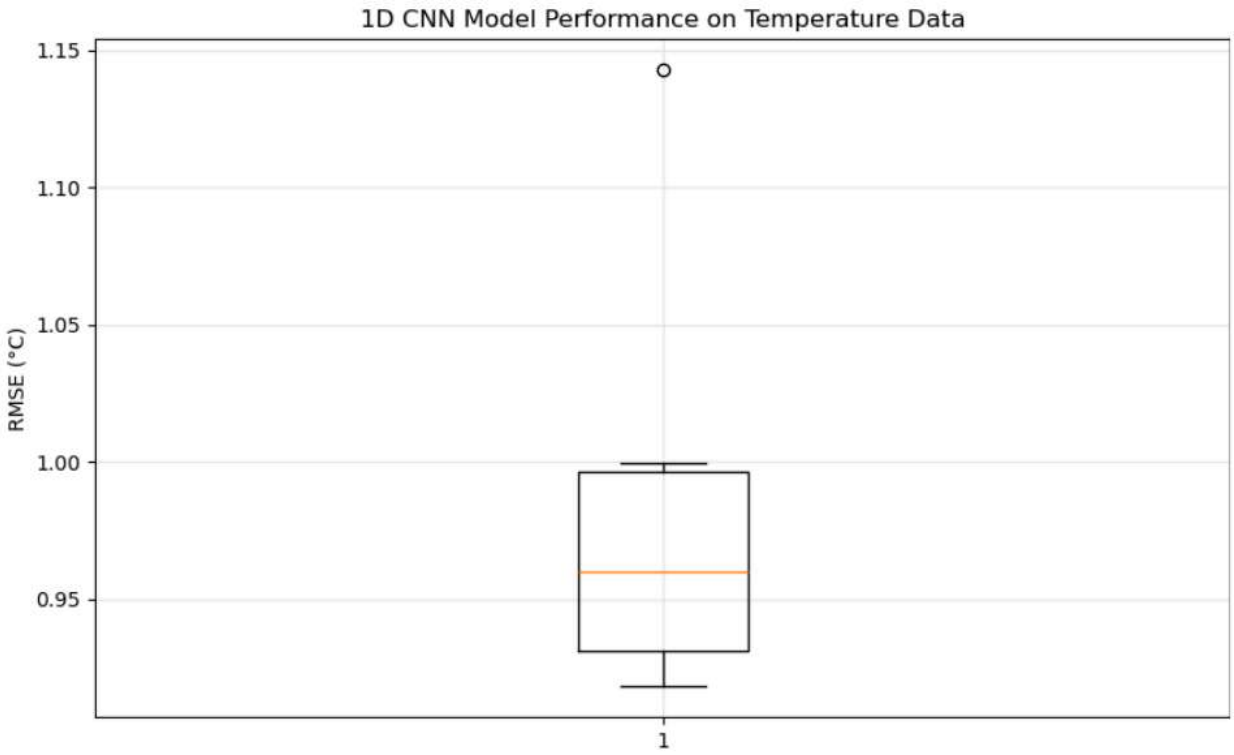

Parmi les modèles de deep learning testés, **LSTM** est le plus performant avec le RMSE le plus faible, confirmant sa capacité à capturer efficacement la dynamique temporelle des données. Les modèles MLP et 1D CNN offrent également de bonnes performances mais restent légèrement moins précis que le LSTM.

6-Conclusion

En conclusion, ce projet a permis d'exploiter un dataset issu de capteurs IoT afin de développer un système complet de prédiction et de surveillance de la température dans un contexte industriel IIoT. L'analyse approfondie des données, incluant le nettoyage, l'extraction de caractéristiques temporelles et l'étude statistique, a révélé des patterns thermiques utiles pour la modélisation. Plusieurs approches de machine learning et de deep learning ont été évaluées, parmi lesquelles les modèles XGBoost et LSTM se sont démarqués par leur précision et leur capacité à capturer les variations temporelles. À partir de ces modèles, un site web interactif a été conçu pour permettre à l'utilisateur de consulter les prédictions, visualiser les tendances et être alerté en cas d'anomalie potentielle. Cette plateforme constitue un outil efficace pour anticiper les risques liés à la surchauffe d'équipements, optimiser la gestion thermique des installations et renforcer la maintenance préventive. Ainsi, ce projet illustre l'apport concret de l'IIoT et de l'intelligence artificielle dans la supervision intelligente des infrastructures modernes.